

林祥庆

☎ 19857150257 ✉ 1192428849@qq.com

🎓 教育经历

苏州大学（211）计算机科学与技术学院 硕士研究生（推免）	2024.09 – 2027.06
专业：计算机科学与技术（学硕） 导师：贾俊铨	
浙江工业大学 计算机科学与技术学院 本科	2020.10 – 2024.06
专业：计算机科学与技术 辅修：智能科学与技术	

🔧 项目/科研经历

LLM 模型推理加速（推测解码优化）	2025.04 – 至今
技术栈：PyTorch、Transformers、Speculative Decoding、KV Cache	
- 针对长草稿推测解码中无效计算较多、加速收益不稳定的问题，参与基于软拒绝机制的分支推测解码方案设计，围绕草稿生成、token 采样、KV Cache 复用等环节进行实验验证与论文撰写。 - 设计不同草稿长度、采样设置与模型配置下的消融对比实验，分析 Token 接受率、推理耗时与生成质量之间的变化关系，为方法有效性和适用场景提供实验支撑。 - 构建推理速度、Token 接受率与生成质量等指标的对比实验，方案在不同模型设置下取得约 1.41–3.31× 端到端推理加速，并保持输出质量稳定；目前有 1 篇 EMNLP 论文在投。	
基于 GSM8K 的大模型 LoRA SFT 与偏好对齐实验	2025.01 – 2025.03
技术栈：LLaMA-Factory、TRL、PEFT、LoRA、DPO、GRPO	
- 面向数学推理任务中指令格式、解题过程与最终答案输出不稳定的问题，基于 LLaMA-Factory 搭建可复用的 LoRA SFT 流程，将 GSM8K 清洗并整理为数学推理指令样例。 - 围绕 LLaMA3 / Qwen2.5 系列模型设计统一训练配置与评测模板，支持从小参数模型到 7B/8B 模型的横向对比，分析模型规模、指令微调状态对 SFT 效果的影响。 - 基于 TRL 在 SFT checkpoint 上进行 DPO 与 GRPO 微调，构造 chosen-rejected 偏好样例并设计答案正确性/格式奖励函数，形成覆盖 SFT、偏好数据构造与偏好对齐的完整实验流程。	

🏢 实习经历

Philips Agent 开发实习生（苏州）	2026.03 – 2026.05
技术栈：LangChain/LangGraph、Agent、vLLM、RAG、Ollama、Workflow、Docker、FastAPI	
- 面向企业自然语言问数中表结构召回、SQL 校验与结果解释链路分散的问题，基于 LangGraph 编排 RAG 表结构检索、Text2SQL、SQL 校验重试、代码执行与结果解释节点。 - 针对表结构召回不足的问题，补充表字段、业务样例与指标口径描述，优化 RAG 召回方法，将数据表召回率从 61.4% 提升至 81.6%。 - 编写自动测试脚本输出召回率、节点耗时与端到端响应时间等指标，定位主要耗时节点后调整 workflow 编排和代码执行流程，将业务响应时间从 50s 降至 30s。	
上海诺基亚贝尔股份有限公司 后端开发/数据清洗实习生（杭州）	2023.09 – 2024.01
面向 Robot Framework 自动化测试脚本生成的模型微调需求，负责后端接口实现与训练数据准备；对原有 Robot Framework 自动化测试代码进行清洗、解析与样例提取，完成格式规范化和微调训练数据构造。	

❤️ 获奖情况

第二届开放原子大赛 Teco-RAG 大模型开发任务挑战赛三等奖（独立完成，奖金 2 万元）	2025.04
第二届开放原子大赛 Tecorigin 算子开发任务挑战赛优秀奖（独立完成，奖金 5 千元）	2025.04
第十四届中国大学生服务外包创新创业大赛国家三等奖	2023.07
2023 年华为智能基座奖学金	2023
2022 中国移动创客马拉松大赛最具发展潜力奖（奖金 1 万元）	2022.10